Laporan Tugas Besar 1
IF3270 - Pembelajaran Mesin

Oleh kelompok 22:

Nama	NIM
Renaldy Arief Susanto	13522022
Kristo Anugrah	13522024
Nyoman Ganadipa Narayana	13522066

Daftar Isi

1. Deskripsi Persoalan

Pada tugas ini, mahasiswa diminta untuk mengimplementasikan modul untuk algoritma ***forward propagation*** pada CNN (*Convolutional Neural Network*) dan RNN (*Recurrent Neural Network*) *from scratch*, sebagaimana yang telah dipelajari di perkuliahan. Bobot untuk *forward propagation* diperoleh dari *training* yang dilakukan dengan library `keras`. Algoritma diimplementasikan dalam bahasa Python dan akan diuji dengan variasi parameter tertentu (seperti jumah layer, jenis layer, dan lainnya).

2. Pembahasan

2.1 Penjelasan Implementasi

Pada subbab ini akan dijelaskan tentang implementasi model FFNN.

2.1.1 Deskripsi Kelas, Atribut dan Metode

Berikut adalah struktur proyek. Catatan: ada direktori atau *file* yang tidak ditampilkan karena tidak relevan, misalnya *script* untuk *testing* atau folder penyimpanan *weights*.

```
.
├── __init__.py
├── activation_functions
│   ├── __init__.py
│   ├── base.py
│   ├── relu.py
│   ├── sigmoid.py
│   ├── softmax.py
│   └── tanh.py
├── layers
│   ├── __init__.py
│   ├── avg_pooling2d.py
│   ├── base.py
│   ├── bidirectional_rnn.py
│   ├── conv2d.py
│   ├── dense.py
│   ├── dropout.py
│   ├── embedding.py
│   ├── flatten.py
│   ├── lstm.py
│   ├── max_pooling2d.py
│   └── simple_rnn.py
├── models
│   ├── __init__.py
│   ├── cnn.py
│   ├── lstm.py
│   └── rnn.py
├── playgrounds
│   ├── gana_rnn.ipynb
│   ├── kristo_cnn.ipynb
│   ├── lstm.ipynb
│   └── starter.py
└── utils
    ├── __init__.py
    ├── data_loader.py
    ├── keras_weight_loader.py
    ├── metrics_calculator.py
    └── text_preprocessor.py
```

Intinya, model-model *from scratch* disimpan di modul `models`, dan pada model-model tersebut melakukan import dari modul `layers` serta modul `activation_functions`. Kemudian, ada folder `utils` yang digunakan untuk memuat dan memproses data, memuat bobot, serta melakukan kalkulasi metrik.

Masing-masing model mempunyai dua metode yang utama, yaitu `forward` untuk melakukan *forward propagation*, serta `set_weights` atau `load_weights` untuk memuat *weights*. **Khusus untuk CNN, bisa dihitung *loss*, dilakukan *training*, dan *back propagation*.**

Modul layers mengandung seluruh definisi jenis layer yang akan digunakan, dan pada masing-masing kelas layer mempunyai metode `forward` untuk *forward propagation*, dan juga `set_weights` atau `load_weights` untuk dipanggil secara iteratif oleh model *neural network*. Tentunya ada detail implementasi lain yang spesifik ke masing-masing jenis layer. Satu contoh saja, pada layer LSTM didefinisikan sebuah kelas `LSTMCell` yang mempunyai metode `forward_step` dan ini berguna untuk melakukan satu *time step* pada sel LSTM.

Untuk *activation functions*, tidak dibahas karena merupakan jangkauan tugas besar 1.

2.1.2 Penjelasan Forward Propagation

Penjelasan-penjelasan pada bagian ini tidak mengulang penjelasan lengkap *forward propagation* dari awal, melainkan hanya ulasan singkat kemudian cuplikan implementasi berbentuk *pseudocode* (atau kode aslinya).

CNN

CNN adalah sebuah *feedforward neural network* dengan satu atau lebih ***convolution layer***. Convolution layer adalah pembeda CNN dengan FFNN biasa, layer ini didesain untuk mengatasi permasalahan ***spatial locality*** (menginterpretasi data dengan tambahan konteks posisi relatifnya terhadap data lain) dan juga menerima **input data dengan dimensi lebih**.

Cara kerja CNN adalah sebagai berikut. Bobot yang pada FFNN bentuknya adalah vektor kolom kini berupa kumpulan matriks, disebut dengan **kernel**. Perhatikan gambar berikut.

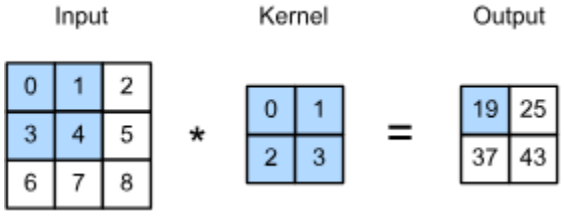

Pada gambar ini, ada satu input berdimensi $1\times3\times3$, dan satu kernel berukuran $1\times2\times2$. Output sebuah sel diperoleh dengan **jumlah dari *component wise multiplication*** pada elemen-elemen di matriks kernel dan matriks input. Jadi, untuk contoh di atas, nilai 19 diperoleh dari $(0\times0)+(1\times1)+(3\times2)+(4\times3)=19$.

Satu kernel diadakan untuk masing-masing pasangan input matrix dan output matrix. Jadi. misal ada input berukuran 7×7 dengan 4 channel dan *batch size* 3, kemudian ingin dipetakan menjadi 2 matriks output. Artinya, akan dipelajari kernel sebanyak:

$$(4 \text{ channel}) \times (2 \text{ output count}) = 8 \text{ kernel}$$

Kemudian ukuran matriksnya bergantung pada *stride* dan *padding*, tetapi kami tidak mengimplementasi *stride* dan *padding* sehingga ukuran matriks ditentukan langsung oleh kami.

Note: penggunaan istilah **kernel** ini sebenarnya salah jika mengacu pada materi kuliah. Rupanya istilah **filter** lebih tepat, sedangkan kernel mengacu ke sekumpulan filter untuk satu proses konvolusi ke satu output. Jadi, pada contoh sebelumnya, ada **2 kernel**. Namun, pada kenyataannya mayoritas penggunaan kedua istilah ini bersifat *interchangeable* dan tidak begitu diperhatikan.

Berikut cuplikan kode kami untuk proses *forward propagation* pada sebuah *convolutional layer*.

```
for b in range(batch_size):
  for f in range(self.filters):
    for i in range(out_height):
      for j in range(out_width):

        # Extract partial input matrix
        patch = x[b, i:i+self.kernel_size[0], j:j+self.kernel_size[1],:]

        # Convolution operation
        output[b,i,j,f] = np.sum(patch*self.weights[:,:,:,f]) + self.biases[f]
```

RNN

Recurrent Neural Network merupakan ekstensi dari FFNN biasa dengan ciri khas **memiliki memori internal**. Setelah menghasilkan output, output tersebut disalin dan dikirim kembali ke recurrent network. Kemudian untuk membuat sebuah keputusan, RNN mempertimbangkan input saat ini dan output yang telah dipelajari dari input sebelumnya.

Desain ini ditujukan untuk menangani data deret **waktu** atau data yang melibatkan **urutan**. FFNN biasa hanya dimaksudkan untuk titik data yang independen satu sama lain.

Namun, jika kita memiliki data dalam urutan sedemikian rupa sehingga satu titik data bergantung pada titik data sebelumnya, kita perlu memodifikasi *neural network* untuk menggabungkan ketergantungan antara titik data ini.

Cara kerja RNN adalah sebagai berikut. Perhatikan *neural network* berikut yang telah disimplifikasi tampilannya.

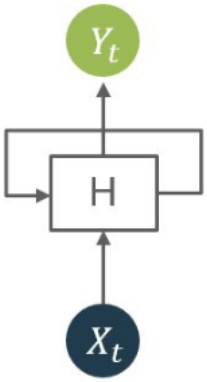

Pada gambar di atas, X_t adalah input, H adalah output pada hidden layer (layaknya FFNN biasa), dan Y_t adalah output. Perhatikan bahwa ada **panah dari H ke dirinya sendiri**. Ini menunjukkan bahwa pada setiap iterasi, output H_t akan digunakan untuk memengaruhi H_{t+1}. Implikasinya, akan ada **bobot** yang dipelajari untuk memetakan pengaruh output yang sudah dihitung ke output-output berikutnya. Seringkali pada RNN, dilakukan istilah *unroll* untuk ilustrasi konsep ini secara lebih nyata.

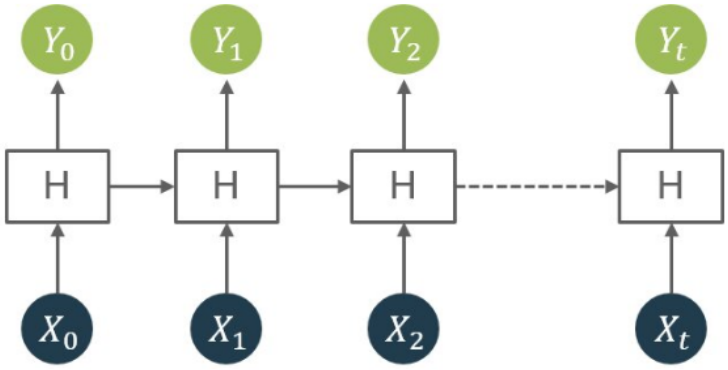

Berikut cuplikan kode kami untuk proses *forward propagation* pada sebuah RNN layer.

```
def forward(self, inputs: np.ndarray) -> np.ndarray:
    if self.rnn_cell is None:
        self.build(inputs.shape)
```

```
    batch_size, seq_length, input_size = inputs.shape

    # Initialize hidden state
    hidden_state = np.zeros((batch_size, self.hidden_size))

    if self.return_sequences:
        outputs = np.zeros((batch_size, seq_length, self.hidden_size))
        for t in range(seq_length):
            hidden_state = self.rnn_cell.forward_step(inputs[:, t, :], hidden_state)
            outputs[:, t, :] = hidden_state

        return outputs

    else:
        # Only return the last hidden state
        for t in range(seq_length):
            hidden_state = self.rnn_cell.forward_step(inputs[:, t, :], hidden_state)

        return hidden_state
```

Kemudian fungsi forward_step pada satu sel RNN adalah seperti berikut.

```
def forward_step(self, input_t: np.ndarray, hidden_t_prev: np.ndarray) ->
np.ndarray:
    # h_t = activation(W_ih @ x_t + W_hh @ h_{t-1} + b_h)
    linear_out = (
        np.dot(input_t, self.W_ih.T) +
        np.dot(hidden_t_prev, self.W_hh.T) +
        self.b_h
    )
    return self.activation.forward(linear_out)
```

LSTM

LSTM adalah jenis RNN dengan detail implementasi yang lebih rumit. Ide intinya sama, kita ingin menginterpretasi data berdasarkan urutan dan konteks, tetapi sebuah masalah pada RNN adalah **tidak ada pengolahan informasi yang diteruskan untuk setiap *time stamp*** sehingga terjadi *vanishing gradient problem*. Kontras dengan itu, LSTM mempunyai sistem yang didesain khusus untuk menangani ini. Simak gambar berikut.

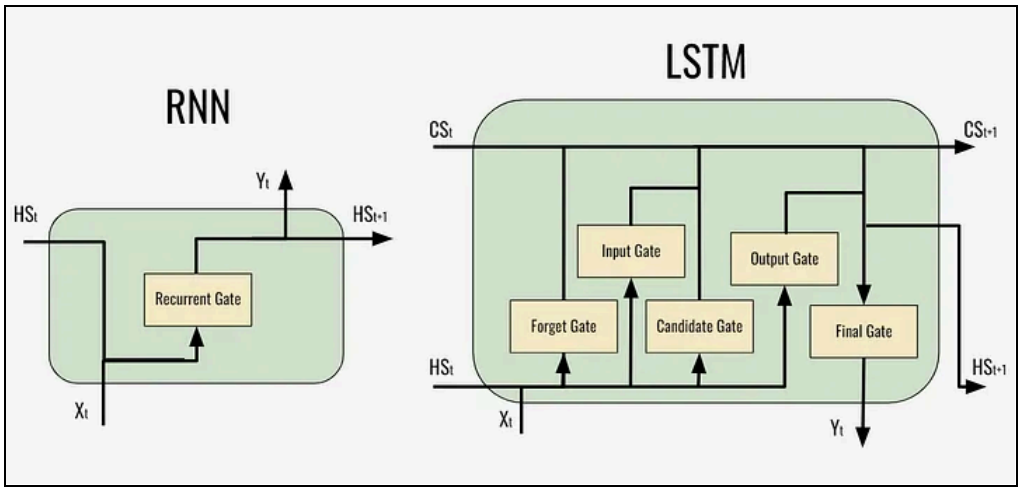

RNN memiliki satu sel memori, yang disebut *hidden state* (dilambangkan HS pada gambar di atas) dan *hidden state* ini tujuannya untuk menyimpan informasi dari masa lalu.

LSTM juga memiliki *hidden state*, tetapi memiliki sel memori lain yang disebut *cell state* (dilambangkan CS pada gambar di atas). Tujuan dari jenis memori baru ini adalah untuk mempelajari pola jangka panjang (dibawa terus menerus secara berkelanjutan), sedangkan *hidden state* biasanya menyimpan lebih banyak informasi jangka pendek.

CS ini akan memengaruhi output dan diolah oleh ***gate-gate* tambahan** pada LSTM.

Berikut adalah cuplikan kode kami yang mengolah CS ini.

```
def forward_step(self, input_t: np.ndarray, hidden_t_prev: np.ndarray,
                 cell_t_prev: np.ndarray) -> Tuple[np.ndarray, np.ndarray]:
    # Input gate
    i_t = self.sigmoid.forward(
        np.dot(input_t, self.W_ii.T) +
        np.dot(hidden_t_prev, self.W_hi.T) +
        self.b_i
    )
    # Forget gate
    f_t = self.sigmoid.forward(
        np.dot(input_t, self.W_if.T) +
        np.dot(hidden_t_prev, self.W_hf.T) +
        self.b_f
    )
    # Candidate values (cell gate)
    g_t = self.tanh.forward(
        np.dot(input_t, self.W_ig.T) +
        np.dot(hidden_t_prev, self.W_hg.T) +
        self.b_g
    )
```

```
    # Output gate
    o_t = self.sigmoid.forward(
        np.dot(input_t, self.W_io.T) +
        np.dot(hidden_t_prev, self.W_ho.T) +
        self.b_o
    )

    # Update cell state
    cell_t = f_t * cell_t_prev + i_t * g_t

    # Update hidden state
    hidden_t = o_t * self.tanh.forward(cell_t)

    return hidden_t, cell_t
```

2.2 Hasil Pengujian

Akan dijelaskan hasil pengujian yang telah dilakukan sebagaimana diminta di spesifikasi tugas. Pengujian secara umum dilakukan di 3 *file* `ipynb` yang terletak pada direktori `src/playgrounds/`.

2.2.1 CNN

Berikut adalah hasil eksperimen dengan beberapa variasi parameter.

Jumlah Layer

Eksperimen dilakukan dengan 3 variasi jumlah layer, yaitu 1, 2, dan 3 layer. Hasil eksperimen dapat dilihat pada 3 grafik di bawah:

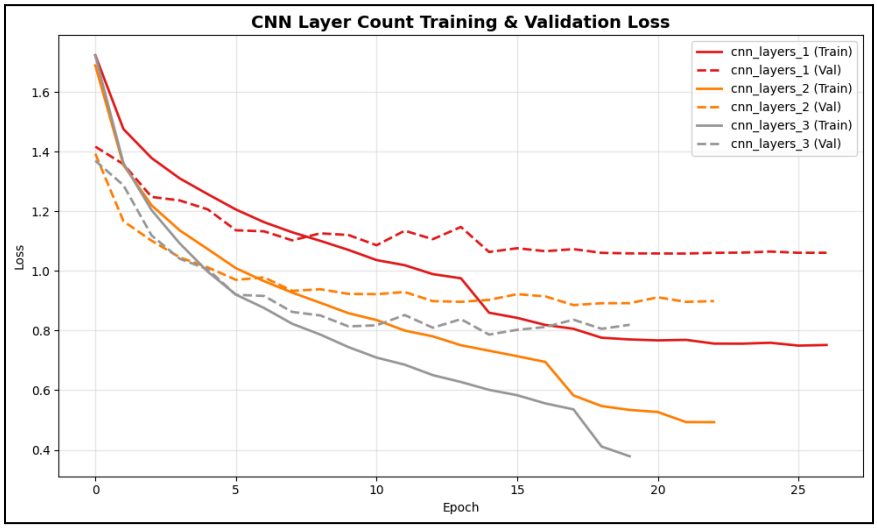

Agar memperjelas, warna **merah** untuk **1 layer**, warna **oranye** untuk **2 layer**, dan **abu-abu** adalah untuk **3 layer**. Kemudian itu berturut-turut adalah pilar **kiri**, **tengah**, dan **kanan** di grafik performa. Dapat dilihat bahwa ada korelasi positif antara jumlah layer dan akurasi/performa.

Berikut adalah performa prediksinya yang dilihat dari nilai *f1-score* dan akurasi.

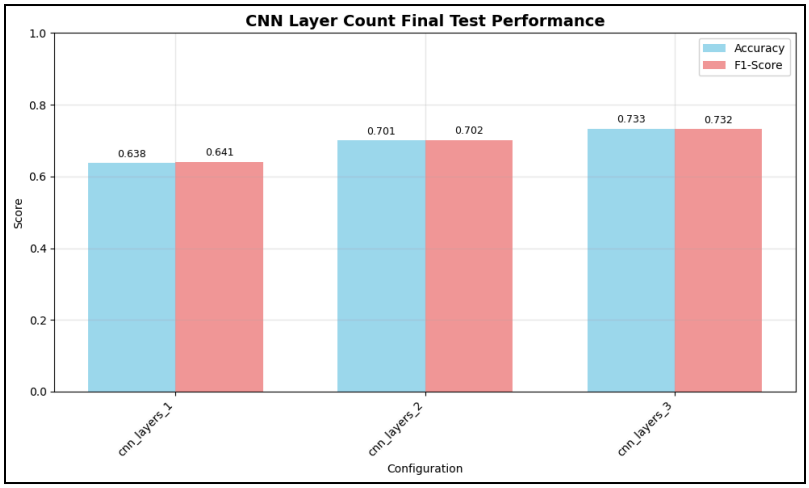

Dapat dilihat dari grafik di atas, CNN dengan 3 layer Conv2D memiliki metrik performa yang paling baik.

Disimpulkan bahwa jumlah layer pada kasus ini berpengaruh **positif** pada performa model.

Jumlah Filter

Eksperimen dilakukan dengan 3 variasi jumlah layer, yaitu 8, 16, dan 32 filter. Hasil eksperimen dapat dilihat pada 3 grafik di bawah:

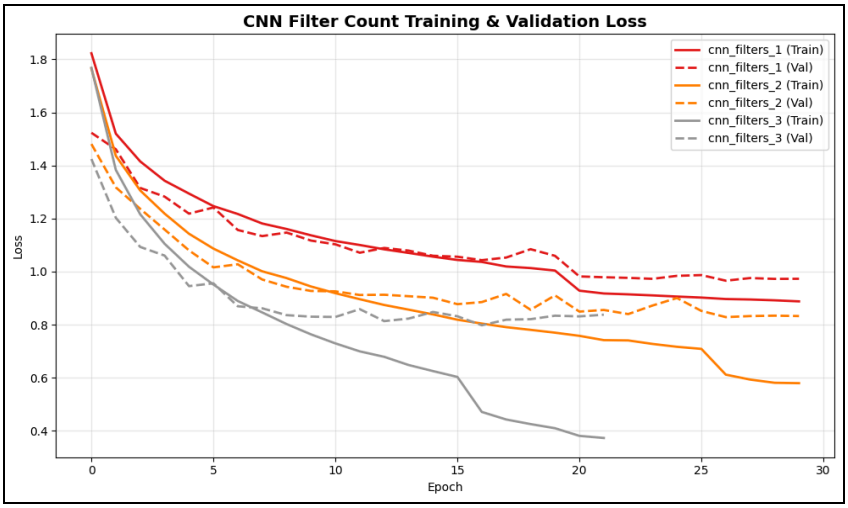

Agar memperjelas, warna **merah** untuk **8 filter**, warna **oranye** untuk **16 filter**, dan **abu-abu** adalah untuk **32 filter**. Kemudian itu berturut-turut adalah pilar **kiri**, **tengah**, dan **kanan** di grafik performa. Dapat dilihat bahwa ada korelasi positif antara jumlah filter dan akurasi/performa.

Berikut adalah performa prediksinya yang dilihat dari nilai *f1-score* dan akurasi.

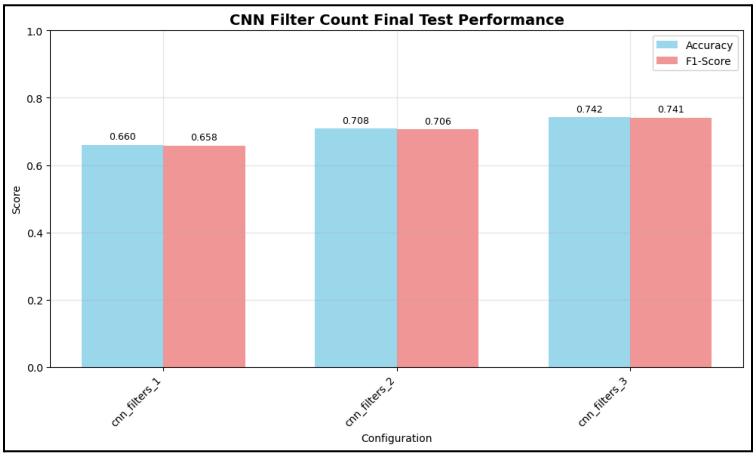

Dapat dilihat dari grafik di atas, CNN dengan 32 filter memiliki metrik performa yang paling baik.

Disimpulkan bahwa jumlah filter pada kasus ini berpengaruh **positif** pada performa model.

Ukuran Filter

Eksperimen dilakukan dengan 3 variasi ukuran filter, yaitu 3×3, 5×5, dan 7×7. Hasil eksperimen dapat dilihat pada 3 grafik di bawah: F1-Score pada grafik kiri bawah, grafik *training* & *validation loss* pada kanan atas, serta akurasi pada grafik kiri atas.

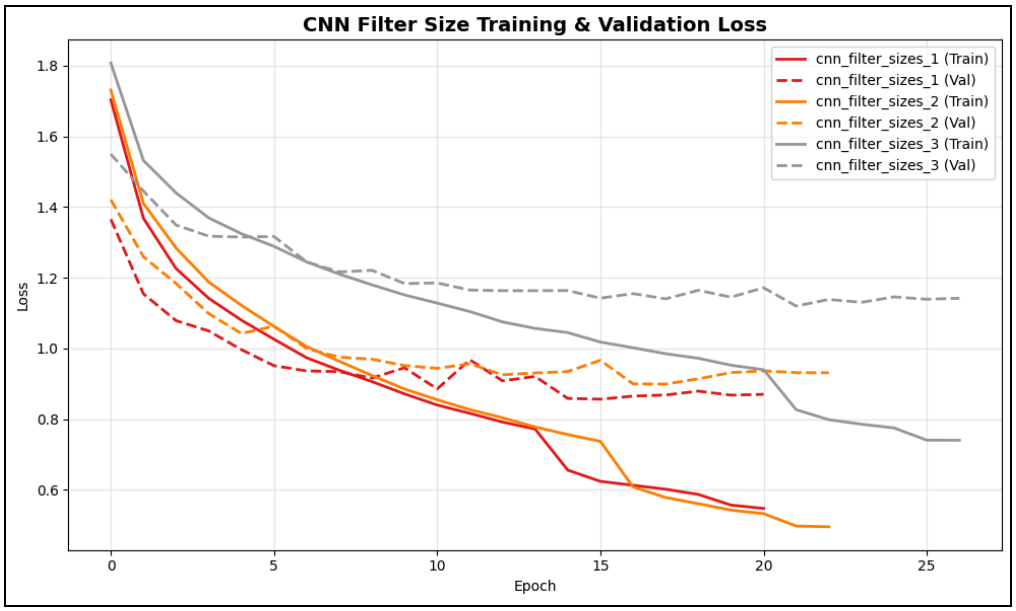

Agar memperjelas, warna **merah** untuk **filter 3×3**, warna **oranye** untuk **filter 5×5**, dan **abu-abu** adalah untuk **layer 7×7**. Kemudian itu berturut-turut adalah pilar **kiri**, **tengah**, dan **kanan** di grafik performa. Dapat dilihat bahwa ada korelasi negatif antara ukuran filter dan akurasi/performa.

Berikut adalah performa prediksinya yang dilihat dari nilai *f1-score* dan akurasi.

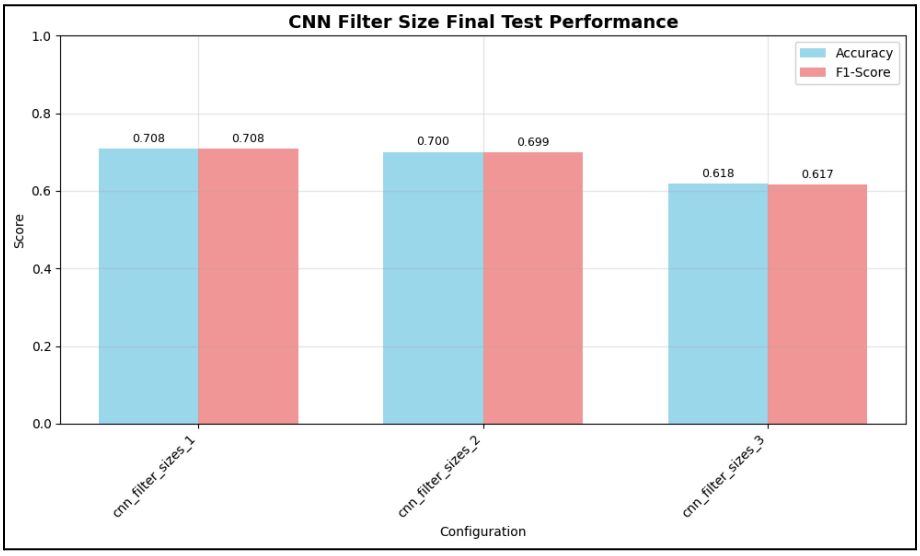

Dapat dilihat dari grafik di atas, CNN dengan filter 3×3 memiliki metrik performa yang paling baik.

Disimpulkan bahwa jumlah filter pada kasus ini berpengaruh **negatif** pada performa model.

Jenis Pooling

Eksperimen dilakukan dengan 2 jenis pooling, yaitu *max pooling* dan *average pooling*. Hasil eksperimen dapat dilihat pada 3 grafik di bawah: F1-Score pada grafik kiri bawah, grafik *training* & *validation loss* pada kanan atas, serta akurasi pada grafik kiri atas.

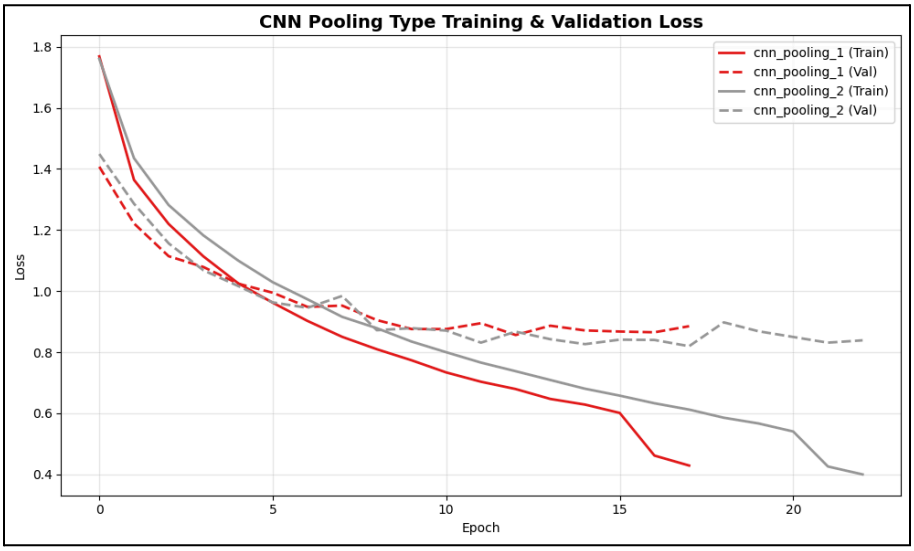

Agar memperjelas, warna **merah** untuk **max pooling**, dan **abu-abu** adalah untuk **average pooling**. Kemudian itu berturut-turut adalah pilar **kiri** dan **kanan** di grafik performa. Dapat dilihat bahwa jenis pooling tidak terlalu memengaruhi akurasi/performa.

Berikut adalah performa prediksinya yang dilihat dari nilai *f1-score* dan akurasi.

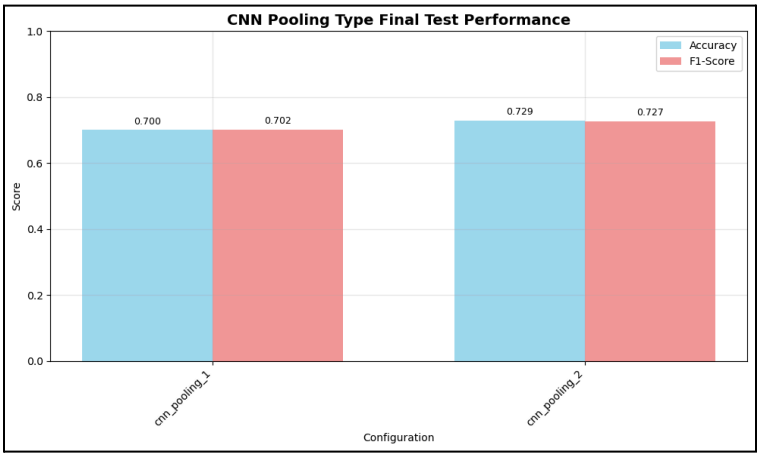

Dapat dilihat dari grafik di atas bahwa CNN dengan **average pooling** memiliki metrik performa yang lebih baik. Hal ini bertolak belakang dengan grafik *loss*, karena pada grafik *loss* CNN dengan layer max pooling memiliki nilai yang lebih kecil. Meskipun begitu, karena nilai *loss* tidak berbeda jauh namun metrik performa kedua konfigurasi memiliki perbedaan

relatif signifikan, disimpulkan bahwa **average pooling** lebih efektif digunakan untuk dataset ini dibanding max pooling.

Disimpulkan bahwa jenis pooling pada kasus ini **average pooling** lebih efektif digunakan dibanding max pooling.

Perbandingan dengan Keras

Model *from scratch* berhasil menyamakan output dengan *forward propagation* menggunakan keras. Perbandingan lebih detail dapat dilihat pada sel terakhir pada *file* pengujian `src/playgrounds/kristo_cnn.ipynb`.

2.2.2 RNN

Berikut adalah hasil eksperimen dengan beberapa variasi parameter.

Jumlah Layer

Eksperimen dilakukan dengan variasi jumlah layer 1, 2, dan 3 layer. Berikut adalah performa prediksinya.

Jumlah Layer	Akurasi	F1-Score
1	0.6350	0.6284
2	0.5225	0.5006
3	0.5325	0.5059

Kemudian berikut adalah grafik *loss* dan *validation loss* terhadap jumlah epoch untuk masing-masing jumlah layer.

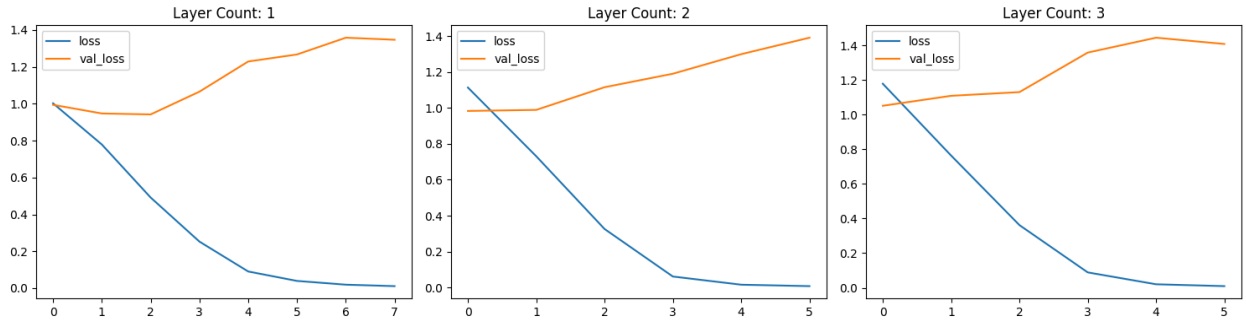

Pada gambar di atas, terlihat bahwa jumlah layer tidak jauh berbeda satu sama lain, tetapi dari F1-Score-nya, jumlah layer 1 merupakan yang terbaik. Kemungkinan ini ada

hubungannya dengan jumlah layer sedikit lebih baik apabila klasifikasi bersifat lebih simpel atau tidak banyak fitur untuk diekstrak dari dataset.

Disimpulkan bahwa jumlah layer yang terlalu besar mungkin terlalu mengekstrak fitur-fitur tertentu sehingga terjadi *overfitting*.

Jumlah Unit/Sel

Eksperimen dilakukan dengan variasi jumlah unit 16, 64, 128, dan 256 unit. Berikut adalah performa prediksinya.

Jumlah Unit	Akurasi	F1-Score
16	0.5200	0.4895
64	0.5800	0.4636
128	0.5000	0.5005
256	0.4775	0.3891

Kemudian berikut adalah grafik *loss* dan *validation loss* terhadap jumlah epoch untuk masing-masing jumlah unit/sel.

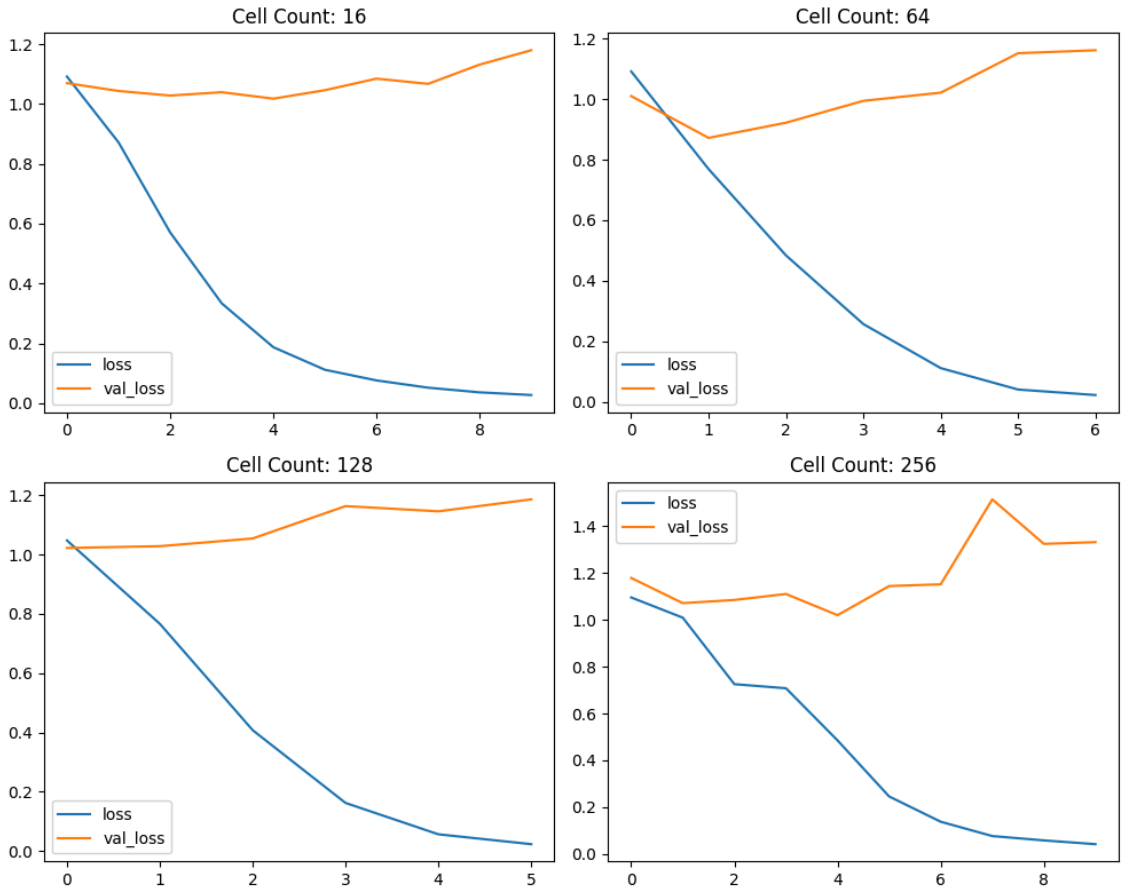

Pada gambar di atas, terlihat bahwa masing-masing jumlah unit stabil pada *validation loss*-nya, kecuali jumlah unit 256 yang mempunyai *spike* di akhir. Selain itu, hanya jumlah unit 256 yang F1-Score-nya relatif lebih jelek dari yang lain.

Disimpulkan bahwa jumlah unit yang terlalu banyak rentan terhadap *overfitting*.

Jenis Layer

Eksperimen dilakukan dengan variasi layer *bidirectional* dan *unidirectional*. Berikut adalah performa prediksinya.

Jenis Layer	Akurasi	F1-Score
Bidirectional	0.6125	0.5586
Unidirectional	0.6150	0.5845

Kemudian berikut adalah grafik *loss* dan *validation loss* terhadap jumlah epoch untuk masing-masing jenis.

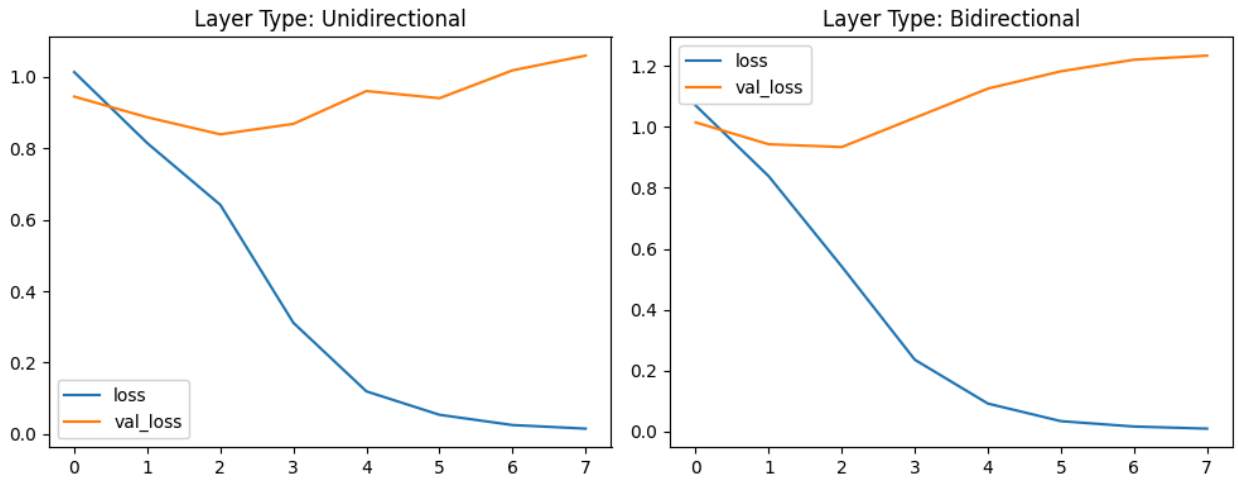

Pada gambar di atas, terlihat bahwa baik *bidirectional* maupun *unidirectional* hampir sama grafik serta performanya.

Oleh karena itu, disimpulkan jenis layer tidak terlalu berpengaruh pada kasus ini.

Perbandingan dengan Keras

Model *from scratch* berhasil menyamakan output dengan *forward propagation* menggunakan keras. Perbandingan lebih detail dapat dilihat pada sel terakhir pada *file* pengujian `src/playgrounds/gana_rnn.ipynb`.

2.2.3 LSTM

Berikut adalah hasil eksperimen dengan beberapa variasi parameter. ***Note:*** karena LSTM pada dasarnya mirip dengan RNN, beberapa penjelasan pada subbagian ini memang sama persis dengan subbagian 2.2.2.

Jumlah Layer

Eksperimen dilakukan dengan variasi jumlah layer 1, 3, dan 5 layer. Berikut adalah performa prediksinya.

Jumlah Layer	Akurasi	F1-Score
1	0.7675	0.7593
3	0.6250	0.4951
5	0.6225	0.4734

Kemudian berikut adalah grafik *loss* dan *validation loss* terhadap jumlah epoch untuk masing-masing jumlah layer.

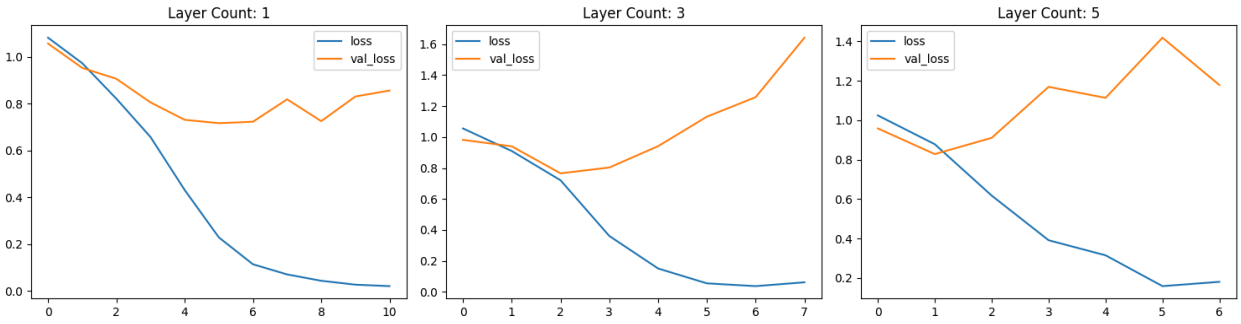

Pada gambar di atas, terlihat bahwa jumlah layer 1 mempunyai grafik *validation loss* yang paling stabil, dan juga mempunyai F1-Score terbesar. Di samping itu, jumlah layer 3 dan 5 mempunyai *spike* mendekati akhir pada grafik *loss* dan *validation loss*-nya. Namun begitu, seluruhnya mempunyai *loss* yang kecil.

Disimpulkan bahwa jumlah layer yang terlalu besar rentan terhadap *overfitting*.

Jumlah Unit/Sel

Eksperimen dilakukan dengan variasi jumlah unit 16, 64, 128, dan 256 unit. Berikut adalah performa prediksinya.

Jumlah Unit	Akurasi	F1-Score
16	0.7550	0.7479
64	0.7675	0.7593
128	0.7375	0.7214
256	0.5925	0.4984

Kemudian berikut adalah grafik *loss* dan *validation loss* terhadap jumlah epoch untuk masing-masing jumlah unit/sel.

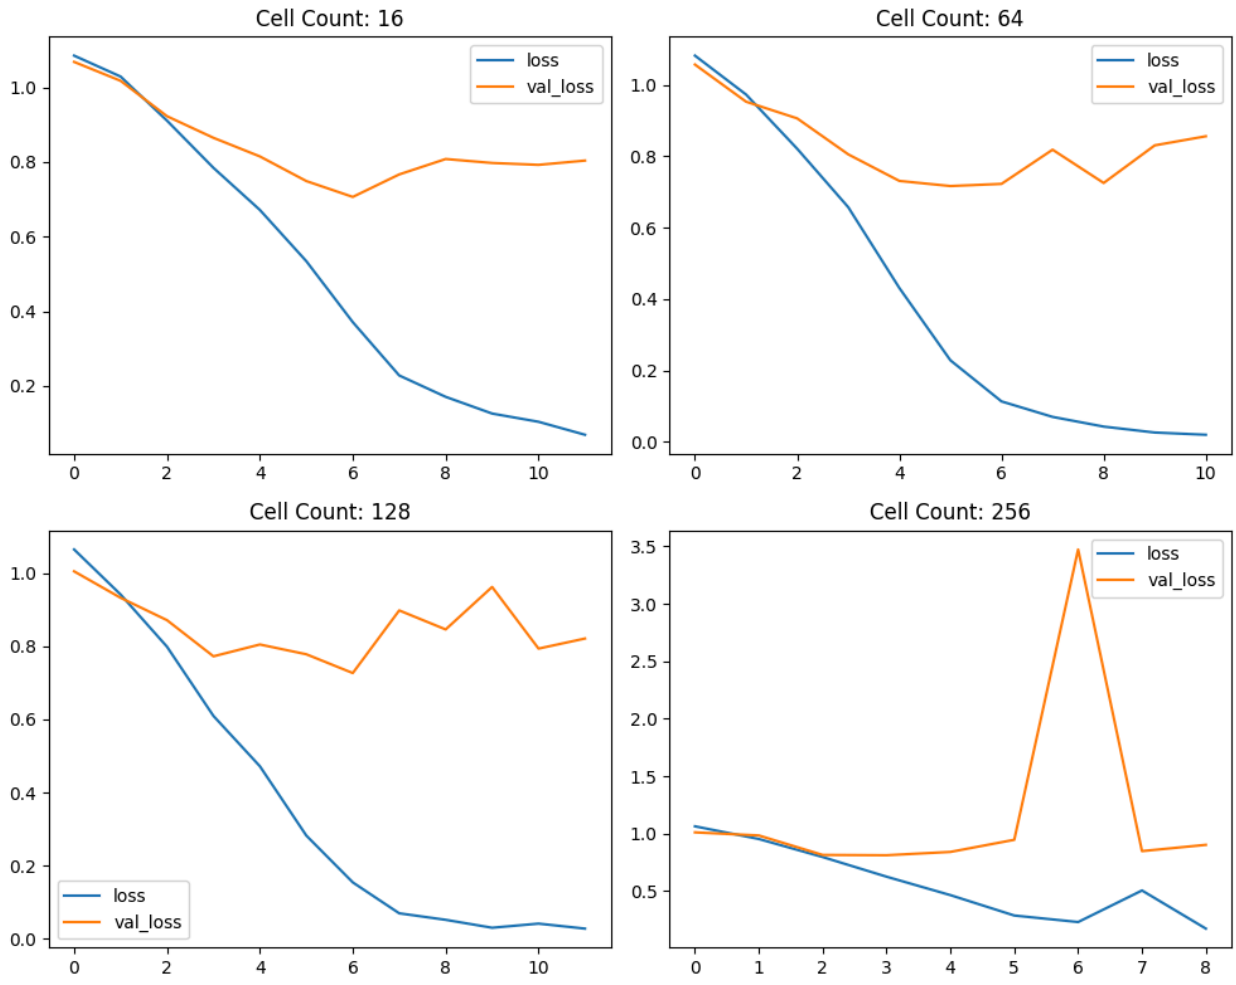

Pada gambar di atas, terlihat bahwa masing-masing jumlah unit stabil pada *validation loss*-nya, kecuali jumlah unit 256 yang mempunyai *spike* di akhir. Selain itu, hanya jumlah unit 256 yang F1-Score-nya relatif lebih jelek dari yang lain.

Disimpulkan bahwa jumlah unit yang terlalu banyak rentan terhadap *overfitting*.

Jenis Layer

Eksperimen dilakukan dengan variasi layer *bidirectional* dan *unidirectional*. Berikut adalah performa prediksinya.

Jenis Layer	Akurasi	F1-Score
Bidirectional	0.7550	0.7479
Unidirectional	0.5950	0.4574

Kemudian berikut adalah grafik *loss* dan *validation loss* terhadap jumlah epoch untuk masing-masing jenis.

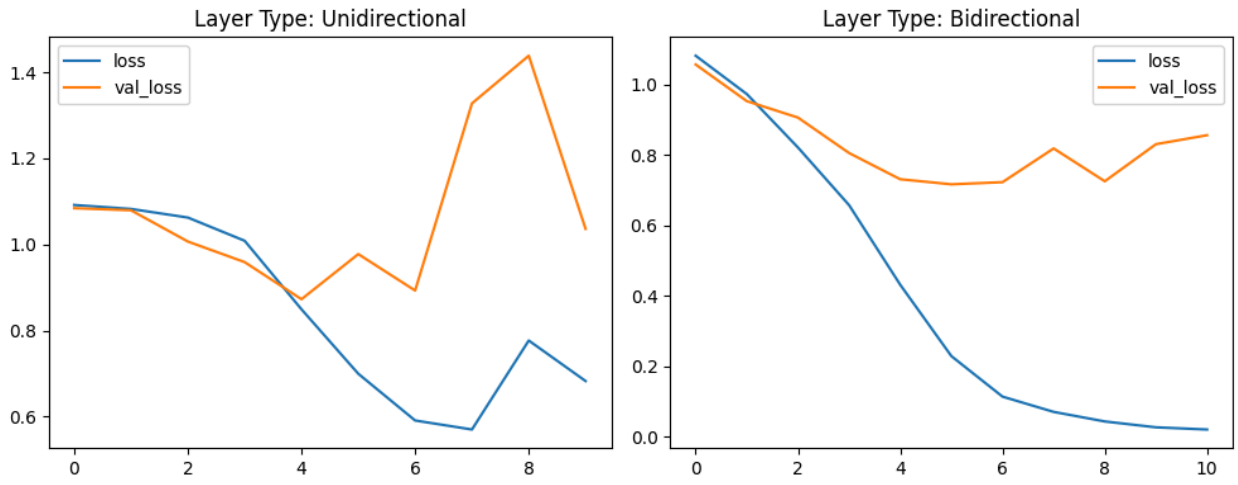

Pada gambar di atas, terlihat bahwa layer bidirectional mempunyai *loss* dan *validation loss* yang lebih stabil secara signifikan. Hal ini diduga karena datanya bersifat kalimat yang kontekstual dan kata-kata yang saling memengaruhi dapat mempunyai urutan yang tidak tentu (bisa kiri ke kanan maupun kanan ke kiri).

Oleh karena itu, disimpulkan *bidirectional layer* memang lebih bagus untuk kasus ini.

Perbandingan dengan Keras

Model *from scratch* berhasil menyamakan output dengan *forward propagation* menggunakan keras. Perbandingan lebih detail dapat dilihat pada sel terakhir pada *file* pengujian `src/playgrounds/aldy_lstm.ipynb`.

3. Kesimpulan dan Saran

Secara keseluruhan, implementasi *forward propagation* dari CNN, RNN, dan LSTM **berhasil** dilakukan secara *from scratch* menggunakan Python dan dapat menyamai hasil model yang dibuat dengan Keras, membuktikan keakuratan logika dan arsitektur yang digunakan.

Berdasarkan hasil eksperimen, beberapa hal tambahan berikut bisa disimpulkan.

1. Pada CNN, penambahan jumlah layer dan filter meningkatkan performa, sedangkan filter berukuran lebih besar justru menurunkan performa. Jenis *pooling* tidak berpengaruh signifikan.
2. Pada RNN, model dengan satu layer menunjukkan performa terbaik, sementara peningkatan jumlah unit atau layer malah cenderung menyebabkan *overfitting*. Layer bidirectional secara signifikan meningkatkan performa.
3. Pada LSTM, hasil serupa dengan RNN ditemukan, yaitu terlalu banyak layer/unit cenderung menyebabkan overfitting, dan penggunaan bidirectional layer menunjukkan performa terbaik.

Kemudian, berikut beberapa saran yang bisa diberikan.

1. Untuk model CNN, sebaiknya gunakan jumlah layer dan filter yang cukup kompleks tetapi tetap seimbang, serta hindari penggunaan ukuran filter yang terlalu besar.
2. Untuk RNN dan LSTM, disarankan menggunakan konfigurasi yang sederhana (jumlah layer dan unit yang tidak berlebihan) agar menghindari overfitting, terutama pada dataset yang tidak terlalu kompleks.
3. Penggunaan bidirectional layer sangat disarankan untuk dataset kontekstual berbasis teks, karena mampu menangkap informasi dari dua arah.
4. Di masa depan, implementasi dapat diperluas dengan mendukung fitur-fitur tambahan seperti padding, stride, dan regulasi seperti dropout atau L2 regularization untuk menambah fleksibilitas dan mencegah overfitting lebih lanjut.
5. Pada akhirnya, untuk meningkatkan performa model perlu proses ***trial and error*** dan tidak ada aturan tetap/baku untuk variasi parameter terbaik.

4. Pembagian Tugas Tiap Anggota Kelompok

Berikut adalah tabel pembagian tugas tiap anggota kelompok untuk tugas ini.

Nama	NIM	Pembagian tugas
Renaldy Arief Susanto	13522022	- Implementasi model Keras untuk LSTM - Pengujian untuk LSTM - Laporan bagian RNN, LSTM, dan implementasi - Model Keras untuk LSTM
Kristo Anugrah	13522066	- Implementasi *forward propagation* untuk CNN - Pengujian untuk CNN - Laporan bagian CNN - Model Keras untuk CNN
Nyoman Ganadipa Narayana	13522114	- Implementasi forward propagation untuk RNN dan LSTM - Pengujian untuk RNN - Model Keras untuk RNN

5. Referensi

---

https://d2l.ai/chapter_convolutional-neural-networks/why-conv.html

https://www.shiksha.com/online-courses/articles/introduction-to-recurrent-neural-network/

https://d2l.ai/chapter_recurrent-modern/lstm.html

https://stackoverflow.com/questions/48714407/rnn-regularization-which-component-to-regularize/58868383#58868383

https://medium.com/@CallMeTwitch/building-a-neural-network-zoo-from-scratch-the-long-short-term-memory-network-1cec5cf31b7

https://stackoverflow.com/questions/50659482/why-cant-i-get-reproducible-results-in-keras-even-though-i-set-the-random-seeds

*Format dokumen ini mengikuti style **Archlinux wiki**.*